



Predicción del impacto de noticias

Aprendizaje automático basado en Regresión Lineal



Descripción del problema

- ¿Se puede predecir el impacto de una noticia a partir de un embedding simple? (TF-IDF)
 - Para ello, utilizaremos un dataset que hemos generado haciendo web scraping (con fin académico) en la web de noticias <https://meneame.net/>.
 - El objetivo es determinar el impacto que tiene cada noticia a través del número de comentarios y el número de clicks.



Descripción del Data Set

- **Texto:** Contiene el titular de la noticia y el párrafo de introducción
- **Comentarios:** Número de comentarios (fecha 19/03/20206).
- **Clicks:** Número de clicks (fecha 19/03/20206).
- **Etiqueta:** Categoría de la noticia (Tecnología, Cultura o Política). Este atributo lo usaremos en el proyecto 4.
- **A partir de la columna 5:** Una columna para cada una de las 50 palabras más relevantes del corpus (texto de todas las noticias) y su relevancia dentro de esa noticia concreta.



Se pide

- **Elabora un script que:**
 - Procese el dataset
 - Son dos problemas en uno, estimar el número de **comentarios** y el de **clicks**.
Se trata de generar dos modelos de regresión. Por cada uno de ellos:
 - Genere 10 modelos de regresión lineal, calcula el error medio de cada uno e indica cuál es “el mejor”.
 - Obtenga los coeficientes de cada atributo del mejor modelo.
 - Identifique el ejemplo con mayor error absoluto generado por el modelo (puedes emplear otras métricas).
 - Implemente el código necesario para responder a las cuestiones.





Analiza los datos - Dependencia lineal

- Visualiza la **dependencia lineal** entre las variables

- Usa la función [scatter.smooth](#):

■ `scatter.smooth(x=data$x, y=data$y, main="X vs. Y")`





Analiza los datos - Correlación

- Calcula la **correlación** que existe entre cada atributo y el objetivo
 - Usa la función cor: `cor(data$y, data$x)`
 - Valores próximos a 1 o -1 indican la existencia de buena correlación.
 - Baja correlación = $-0.2 < x < 0.2$



Crea el modelo de regresión lineal

- Divide el dataset en entrenamiento (70%) y test (30%)
 - Utiliza la función `createDataPartition`
 - `createDataPartition(y=data$target, p=0.7, list=FALSE)`
 - **Target** representa el nombre el atributo a predecir.
- Entrena el modelo de regresión lineal
 - Utiliza la función `lm` // `lm(formula = ¿?, data = training_data)`
 - `formula=target~.` (usa todos los atributos del data.frame)
 - `formula=target~Att-1+Att-2+...+Att-N` (usa sólo algún atributo)
- Valida el modelo: `predict(model, test_data)`
- Calcula el error medio absoluto del modelo (Mean Absolute Error)
 - `mean(abs(prediction - test_data$Target))`



Analiza el modelo de regresión lineal

- Obtén los coeficientes del modelo de regresión lineal
 - Usa la función print: `summary(model)`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	686.852	527.290	1.303	0.193865
Batting_average	-2315.678	4078.164	-0.568	0.570647
On.base_percentage	100.318	4008.288	0.025	0.980052
Runs	-1.191	7.640	-0.156	0.876229
Hits	10.155	4.386	2.315	0.021392 *
Doubles	-6.892	11.883	-0.580	0.562407
Triples	-2.780	28.990	-0.096	0.923677
HomeRuns	61.650	17.682	3.487	0.000575 ***
Runs_batted_in	7.922	7.121	1.112	0.266956
Walks	10.171	7.038	1.445	0.149645
Strike.Outs	-15.066	3.007	-5.010	1.01e-06 ***
Stolen_bases	13.091	6.489	2.017	0.044686 *
Errors	-19.927	10.020	-1.989	0.047791 *

El número de asteriscos que posee cada atributo (en la columna derecha de la vista de los coeficientes) indica la significatividad: cuantos más asterísticos, el atributo es más significativo.

Se consideran significativos valores inferiores a 0.05.



Analiza el modelo de regresión lineal

- Confirma si el modelo tiene significación estadística (p-value)

- Usa la función print: `print.model.summary(model)`

```
Residual standard error: 865.4 on 259 degrees of freedom  
Multiple R-squared: 0.5647, Adjusted R-squared: 0.5445  
F-statistic: 28 on 12 and 259 DF, p-value: < 2.2e-16
```

- El valor debe ser inferior o igual a 0,05.

- Tras analizar el modelo

- ¿Se puede mejorar el modelo eliminando alguna variable del dataset?
- Haz pruebas eliminando del modelo las variables con menor relevancia.



Responde a las siguientes preguntas

- **Añade el código que permita responder a las siguientes cuestiones** partiendo de los mejores modelos (justifica cómo respondes a cada una):
 1. Identifica las 10 palabras con mayor coeficiente negativo (para cada modelo)
 2. Identifica las 10 palabras con menor coeficiente negativo (para cada modelo)
 3. Identifica las 10 noticias más «sorprendentes» para cada modelo:
 - Las 5 con mayor diferencia positiva entre el valor real y la predicción.
 - Las 5 con mayor diferencia negativa entre el valor real y la predicción.



Responde a las siguientes preguntas

4. Explora la creación de un generador automático de noticias (simulando la creación de [datos sintéticos](#)):
- Genera 1000 vectores aleatorios con exactamente 5 “unos” (contiene sólo 5 palabras relevantes del corpus). El tamaño del vector será igual al número de palabras del dataset. Usa los 2 modelos para predecir los clicks y comentarios para cada vector.
 - Identifica los 10 vectores con más comentarios. ¿Qué palabras contienen? Esas palabras se corresponden a las posiciones con valor 1 en el vector.
 - Identifica los 10 vectores con más clicks. ¿Qué palabras contienen? Esas palabras se corresponden a las posiciones con valor 1 en el vector.



Se pide - Documentación

- Documenta el proyecto usando [esta plantilla](#):
 - Análisis de los datos
 - Modelos de regresión lineal
 - Cuestiones teóricas
 - Declaración de uso de la IA
 - Bibliografía



Entrega

- Entrega el trabajo a través de la tarea de ALUD
 - Fecha de entrega: 15 mayo
 - Formato: fichero .ZIP
 - Completa el cuestionario de tiempos y dificultades
- Evaluación - 10%
 - Ejecución correcta y libre de errores - 5%
 - Documentación de análisis de los resultados - 5%
- Esfuerzo individual
 - 20h. por persona